基于注意力机制的多模态情感分析方法研究

Research on Multimodal Sentiment Analysis Based on Attention Mechanism

张明远[1]　李思琪[1]　王建国[1]

（1. 清华大学 计算机科学与技术系，北京 100084）

E-mail: zhangmy@example.edu.cn

摘　要：针对传统情感分析方法难以充分挖掘文本、语音与视觉模态之间互补信息的问题，本文提出一种基于跨模态注意力机制的多模态情感分析方法（Cross-modal Attention Fusion Network，CAFN）。该方法首先利用预训练模型分别提取三种模态的高层语义特征，随后通过跨模态注意力模块对不同模态特征进行动态对齐与加权融合，最后采用门控机制抑制噪声模态的干扰。在公开数据集 CMU-MOSI 与 CMU-MOSEI 上的实验表明，所提方法在二分类准确率上分别达到 86.3% 与 85.7%，相较于当前主流基线模型平均提升 2.4 个百分点，验证了跨模态注意力融合机制的有效性。消融实验进一步证实了各模块对整体性能的贡献。

关键词：多模态情感分析；注意力机制；特征融合；深度学习；门控网络

中图分类号：TP391　**文献标识码**：A

Abstract: To address the difficulty of fully exploiting complementary information among textual, acoustic and visual modalities in conventional sentiment analysis, this paper proposes a multimodal sentiment analysis method based on cross-modal attention, named Cross-modal Attention Fusion Network (CAFN). High-level semantic features of the three modalities are first extracted by pre-trained models, then dynamically aligned and fused through a cross-modal attention module, and finally a gating mechanism is adopted to suppress noisy modalities. Experiments on the public datasets CMU-MOSI and CMU-MOSEI show that the proposed method achieves binary classification accuracies of 86.3% and 85.7% respectively, outperforming mainstream baselines by an average of 2.4 percentage points.

Key words: multimodal sentiment analysis; attention mechanism; feature fusion; deep learning; gating network

1 引言

随着社交媒体与短视频平台的迅速普及，用户产生的情感表达不再局限于纯文本，而是融合了文本、语音语调与面部表情等多种模态信息。如何综合利用这些异构数据准确判断用户情感倾向，已成为自然语言处理与情感计算领域的重要研究课题。多模态情感分析旨在通过整合多源信息，弥补单一模态在表达能力上的局限，从而获得更鲁棒的情感判别结果。

早期研究多采用特征级或决策级的简单拼接策略，未能充分建模模态之间的交互关系。近年来，随着深度学习的发展，基于循环神经网络与卷积神经网络的融合方法取得了一定进展，但仍存在两方面不足：其一，不同模态对最终情感判别的贡献存在显著差异，简单的等权融合难以突出关键模态；其二，部分模态在采集过程中易受噪声干扰，直接融合会削弱模型的判别能力。

针对上述问题，本文提出一种基于跨模态注意力机制的多模态情感分析方法。其主要贡献包括：（1）设计跨模态注意力模块，实现不同模态特征的动态对齐与自适应加权；（2）引入门控融合机制，有效抑制噪声模态对结果的负面影响；（3）在两个公开基准数据集上进行充分实验，验证了方法的有效性与泛化能力。

2 相关工作

2.1 单模态情感分析

文本情感分析是情感计算的基础任务，传统方法依赖情感词典与人工特征工程。随着 Word2Vec、BERT 等预训练语言模型的出现，基于上下文语义表示的方法显著提升了文本情感判别的精度。语音情感分析则主要利用梅尔频率倒谱系数（MFCC）、基频等声学特征，刻画语调与语速所蕴含的情感线索。视觉情感分析通过分析面部表情、头部姿态等视觉线索，进一步补充了情感判别的信息来源。

2.2 多模态特征融合

多模态融合策略通常分为早期融合、晚期融合与混合融合三类。早期融合在特征层面进行拼接，能够保留模态间的细粒度交互，但对特征维度与对齐要求较高；晚期融合在决策层面整合各模态预测结果，鲁棒性较强但忽略了模态间的深层关联。近年来，基于注意力机制的融合方法因其能够自适应地建模模态重要性而受到广泛关注，并在多个基准任务上取得了领先性能。

3 本文方法

3.1 总体框架

本文所提出的跨模态注意力融合网络（CAFN）由特征提取、跨模态注意力融合与情感分类三个核心模块组成。给定一段包含文本、语音与视觉信息的样本，模型分别提取三种模态的特征序列，经跨模态注意力模块进行交互融合后，输入分类器得到情感极性预测。整体网络以端到端方式进行训练，各模块参数协同优化。

3.2 跨模态注意力机制

设文本、语音、视觉三种模态的特征分别为 X_t、X_a、X_v。跨模态注意力以一种模态作为查询（Query），其余模态作为键（Key）与值（Value），计算注意力权重以实现特征对齐。其核心计算公式如下：

$$Attention(Q, K, V) = softmax(Q \cdot K^T / \sqrt{d_k}) \cdot V \tag{1}$$

其中 d_k 为键向量的维度，缩放因子 $\sqrt{d_k}$ 用于缓解点积过大导致的梯度消失问题。通过该机制，模型能够依据模态间的语义相关性动态分配注意力权重，从而突出对情感判别更具贡献的模态信息。

3.2.1 查询—键—值的构造

为充分挖掘模态间的交互关系，本文以两两配对的方式构造跨模态查询。下面分别从查询向量与键值向量两个层面说明其具体实现。

3.2.1.1 查询向量的生成

以文本模态作为主导模态时，查询向量由文本特征经线性变换得到。其设计动机在于：在多数场景下，文本通常承载最为明确的情感语义，可作为引导其余模态对齐的锚点。

3.2.1.2 键值向量的生成

语音与视觉模态的特征分别经独立的线性变换映射为键向量与值向量，从而在与查询向量交互时保留各自模态特有的情感线索。具体地，键值向量的构造需满足维度对齐、尺度归一化与位置编码三方面要求：首先将各模态键值向量统一映射到相同的隐藏维度，以确保注意力点积运算的可行性；其次对键向量进行层归一化处理，缓解不同模态特征数值尺度差异带来的训练不稳定；最后在序列特征上叠加相对位置编码，使模型能够感知模态内部的时序结构信息。

3.2.2 多头注意力的并行计算

在上述查询—键—值构造的基础上，本文采用多头机制并行计算多组注意力，使模型能够从不同的表示子空间捕获模态间的多样化关联，最终将各注意力头的输出拼接并经线性投影得到融合表示。

3.3 门控融合与分类

为抑制噪声模态的干扰，本文在融合阶段引入门控机制。门控向量 g 通过 Sigmoid 激活函数计算各模态的可信度权重，融合特征 F 由下式给出：

$$F = g \odot X_{att} + (1 - g) \odot X_{res} \tag{2}$$

最终，融合特征经全连接层与 Softmax 分类器输出情感类别。模型采用交叉熵损失进行端到端优化，并通过 Dropout 与权重衰减缓解过拟合问题。

4 实验与结果分析

4.1 数据集与评价指标

本文在两个广泛使用的多模态情感分析数据集 CMU-MOSI 与 CMU-MOSEI 上进行实验。前者包含 2199 条意见视频片段，后者规模更大，包含约 23000 条样本。评价指标采用二分类准确率（Acc-2）、F1 值与平均绝对误差（MAE）。所有实验在相同的数据划分与超参数设置下重复三次，报告平均结果。

4.2 实验结果

表 1 给出了本文方法与主流基线模型的对比结果。可以看出，CAFN 在两个数据集上的各项指标均取得了最优表现，验证了跨模态注意力融合机制的有效性。

表 1 不同方法在 CMU-MOSI 与 CMU-MOSEI 上的性能对比

方法	MOSI Acc-2	MOSI F1	MOSEI Acc-2	MOSEI F1
TFN (2017)	80.8	80.7	82.5	82.1
LMF (2018)	82.5	82.4	82.0	82.1
MulT (2019)	83.0	82.8	82.5	82.3
MISA (2020)	84.0	83.9	84.2	84.0
本文 CAFN	**86.3**	**86.1**	**85.7**	**85.5**

为更直观地展现各方法的性能差异，图 1 以分组柱状图的形式对比了五种方法在两个数据集上的二分类准确率。可以看出，随着融合策略的不断改进，模型准确率呈稳步上升趋势，本文方法在两个数据集上均显著领先于其余基线。

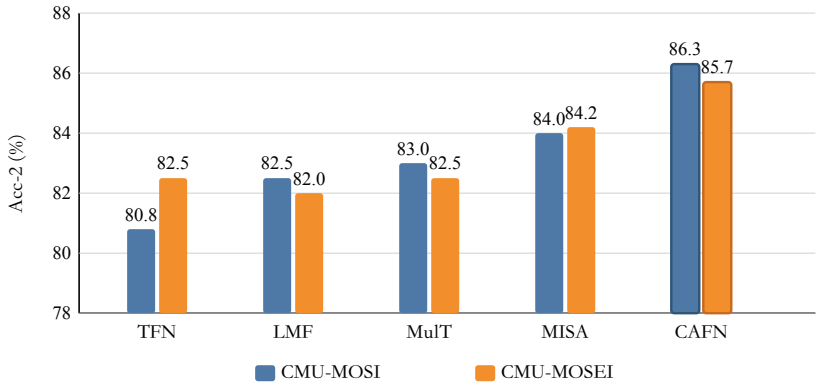


图 1 不同方法二分类准确率分组柱状图对比

4.3 消融实验

为验证各模块的有效性，本文进行了消融实验。移除跨模态注意力模块后，模型在 CMU-MOSI 上的准确率下降约 1.8 个百分点；进一步移除门控融合机制后，准确率再下降 1.1 个百分点。这表明两个核心模块对整体性能均具有显著贡献，二者相辅相成，共同提升了模型的情感判别能力。

4.4 训练收敛性分析

图 2 给出了本文方法与典型基线 MulT 在 CMU-MOSI 验证集上的准确率随训练轮次的变化曲线。可以看出，CAFN 不仅收敛速度更快，且在约第 25 轮后趋于稳定并维持在更高的准确率水平，表明跨模态注意力与门控机制有助于模型更高效地学习模态间的判别性表示。

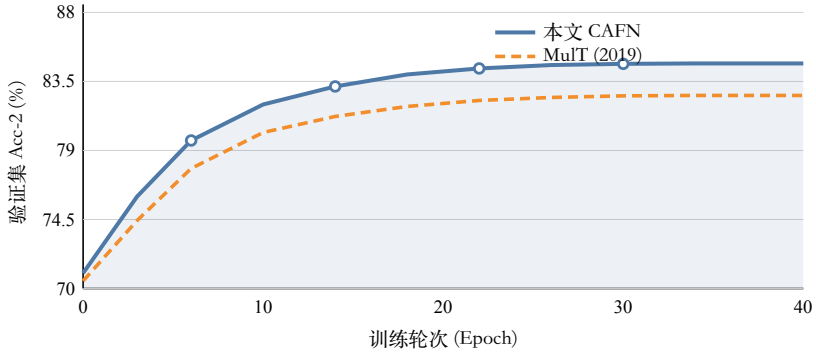


图 2 CAFN 与 MulT 在验证集上的准确率收敛曲线

4.5 多维能力对比

为综合评估模型在不同维度上的表现，图 3 从准确率、F1 值、鲁棒性、推理效率与模态对齐五个维度，对本文方法与 MISA 进行了雷达图对比。结果显示，CAFN 在模态对齐与鲁棒性两个维度上的优势尤为明显，整体能力轮廓更为饱满。

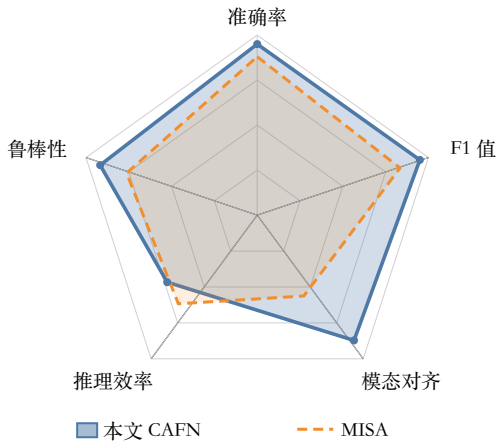


图 3 CAFN 与 MISA 多维能力雷达图对比

4.6 混淆矩阵分析

为进一步剖析模型的分类细节，图 4 给出了 CAFN 在 CMU-MOSI 测试集上的混淆矩阵热力图。可以看出，模型对积极与消极情感的判别准确率均较高，误分类主要集中于情感强度较弱的中性边界样本，这与人工标注中本身存在的模糊性相吻合。

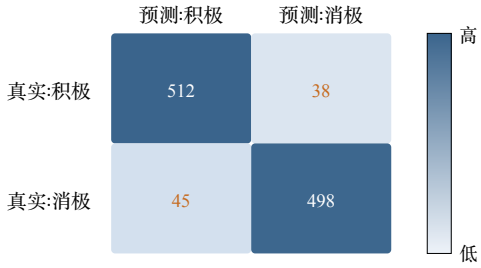


图 4 CAFN 在 CMU-MOSI 测试集上的混淆矩阵热力图

5 结论与展望

本文针对多模态情感分析中模态贡献不均与噪声干扰的问题，提出了一种基于跨模态注意力机制的融合方法 CAFN。该方法通过跨模态注意力实现特征动态对齐，并借助门控机制抑制噪声模态。在两个公开数据集上的实验充分验证了方法的有效性与鲁棒性。未来工作将进一步探索更高效的模态对齐策略，并将该方法拓展至对话级情感识别与跨语言情感分析等更复杂的应用场景。

参考文献

[1] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis[C]. EMNLP, 2017: 1103-1114.

[2] Liu Z, Shen Y, Lakshminarasimhan V B, et al. Efficient low-rank multimodal fusion with modality-specific factors[C]. ACL, 2018: 2247-2256.

[3] Tsai Y H, Bai S, Liang P P, et al. Multimodal transformer for unaligned multimodal language sequences[C]. ACL, 2019: 6558-6569.

[4] Hazarika D, Zimmermann R, Poria S. MISA: Modality-invariant and -specific representations for multimodal sentiment analysis[C]. ACM MM, 2020: 1122-1131.

[5] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. NAACL, 2019: 4171-4186.

[6] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. NeurIPS, 2017: 5998-6008.